Algorytmy sztucznej inteligencji w Przemyśle 4.0 [P]

Inteligentny system wykrywania i kategoryzacji odpadów

Mateusz Buchczyk (272816), Remigiusz Szmyt (272819)

11 listopada 2026

1 Cel i zakres projektu

1.1 Cel projektu

Celem projektu jest stworzenie kompletnego systemu, którego główną funkcjonalnością jest wykrywanie i kategoryzacja odpadów na podstawie obrazów. W ramach projektu przewidziano również badania skupiające się na porównaniu różnych modeli sztucznej inteligencji w tym zastosowaniu. Docelowo zestawione zostaną większe modele wizyjne z modelami lżejszymi, zdolnymi do funkcjonowania na ograniczonych zasobowo urządzeniach brzegowych (ang. *edge computing*). Modele zostaną porównane pod kątem dokładności klasyfikacji, wykorzystania zasobów oraz czasu uzyskania odpowiedzi.

1.2 Zakres projektu

W ramach projektu przewidziano następujące zadania:

- przegląd literatury badawczej i istniejących rozwiązań,
- wybór i dostosowanie zbioru treningowego do wybranego rodzaju modeli,
- trenowanie lub dostrajanie (fine-tuning) modeli na wybranym zbiorze danych,
- uruchomienie modeli na serwerze oraz urządzeniu Radxa,
- przeprowadzenie badań i eksperymentów,
- implementacja aplikacji webowej (obsługa urządzenia Radxa, generowanie raportów dotyczących wykrytych odpadów oraz ewentualne dodatkowe funkcjonalności ustalone w toku prac).

2 Przegląd literatury

2.1 Podręczniki akademickie

Wybrane podręczniki porządkują podstawy sztucznej inteligencji, uczenia maszynowego oraz metodykę projektowania systemów wizyjnych. Stanowią one punkt wyjścia do omówienia algorytmów detekcji i kategoryzacji odpadów, uzasadnienia wyboru architektur modeli oraz metodyki ich porównania na serwerze i urządzeniu brzegowym.

2.1.1 Russell i Norvig: Artificial Intelligence: A Modern Approach

Podręcznik Russella i Norviga przedstawia sztuczną inteligencję jako dziedzinę obejmującą m.in. percepcję, rozumowanie, podejmowanie decyzji oraz uczenie [1]. Dla projektu istotne są części dotyczące percepcji wzrokowej oraz pojęcia agenta racjonalnego działającego w warunkach ograniczonych zasobów (racjonalność ograniczona, ang. *bounded rationality*).

Źródło wybrano jako ogólną podstawę pojęciową projektu. Pozwala ono opisać system w kategoriach agenta, który na podstawie obrazu z kamery podejmuje decyzję o kategorii odpadu, a urządzenie brzegowe (Radxa) i serwer traktować jako środowiska o różnych zasobach obliczeniowych. Z tej perspektywy istotny jest kompromis między dokładnością modelu a czasem odpowiedzi i zużyciem zasobów, co odpowiada zakresowi planowanych porównań. Podręcznik ma charakter ogólny i nie dotyczy wprost detekcji odpadów, dlatego służy wyłącznie jako rama pojęciowa.

2.1.2 Zhou: Machine Learning

Książka Zhi-Hua Zhou obejmuje podstawy uczenia maszynowego, w tym ocenę i wybór modeli, generalizację, selekcję cech oraz techniki walidacji [2]. Szczególnie istotne są rozdziały poświęcone ocenie jakości klasyfikatorów, miarom wydajności (m.in. precyzja, czułość, F1-score) oraz błędom uwzględniającym różne koszty pomyłek.

Pozycję wybrano jako teoretyczne zaplecze oceny jakości klasyfikacji odpadów (np. precision, recall, F1-score, macierz pomyłek). W projekcie koszty błędów mogą się różnić w zależności od rodzaju odpadu, co uzasadnia analizę metryk dla poszczególnych klas, a nie wyłącznie dokładności ogólnej. Omówione w książce zasady podziału danych i doboru hiperparametrów uzasadniają testowanie wszystkich porównywanych modeli (np. YOLO i mniejszych sieci mobilnych) na tym samym, niezależnym zbiorze testowym oraz oddzielenie dostrajania modeli od końcowej oceny ich skuteczności. Książka ma charakter ogólny i nie omawia specyfiki widzenia komputerowego, dlatego metryki typowe dla detekcji obiektów (np. mAP) wymagają odwołania do innych źródeł.

2.1.3 Goodfellow, Bengio i Courville: Deep Learning

Podręcznik omawia matematyczne podstawy uczenia maszynowego, sieci głębokie, konwolucyjne sieci neuronowe (CNN), regularyzację, optymalizację, metodykę praktyczną (m.in. dobór hiperparametrów i metryk) oraz uczenie reprezentacji, w tym transfer learning [3]. Rozdział poświęcony zastosowaniom dotyka również widzenia komputerowego oraz zagadnień wydajnych implementacji i kompresji modeli.

Dla projektu istotne są rozdziały o sieciach konwolucyjnych, regularyzacji i optymalizacji oraz o transferze wiedzy, który stanowi podstawę dostrajania wstępnie wytrenowanych modeli. Książkę wybrano jako teoretyczne tło dla architektur konwolucyjnych stosowanych w klasyfikacji i detekcji odpadów oraz dla zagadnień trenowania i dostrajania modeli. Wyjaśnia ona, w jaki sposób kolejne warstwy konwolucyjne uczą się cech od krawędzi i tekstur po struktury wyższego poziomu, co ma znaczenie przy rozróżnianiu materiałów odpadów. Ponieważ publikacja pochodzi z 2016 roku, nie obejmuje nowszych lekkich architektur ani technik wdrożeń na urządzeniach brzegowych; zagadnienia te opisują nowsze źródła (m.in. [6, 10]). Podręcznik nie stanowi również dowodu na wyższość konkretnej architektury w tym zastosowaniu – skuteczność modeli zostanie zweryfikowana empirycznie w eksperymentach na serwerze i urządzeniu Radxa.

2.1.4 Géron: Hands-On Machine Learning

Trzecie wydanie książki Gérona przedstawia praktyczny przebieg projektów uczenia maszynowego z użyciem bibliotek Scikit-Learn, Keras i TensorFlow [4]. Obejmuje m.in. przygotowanie danych, trenowanie i dostrajanie sieci, zagadnienia widzenia komputerowego oraz wdrażanie modeli, w tym na urządzeniach mobilnych i wbudowanych.

Pozycję wybrano ze względu na silne powiązanie teorii z praktyką: budową potoków danych (pipelines), dostrajaniem modeli (fine-tuning) i wdrażaniem. W projekcie niezbędne jest powtarzalne środowisko obejmujące zarówno trening modeli na serwerze, jak i uruchamianie lżejszych wariantów inferencyjnych na urządzeniu Radxa oraz komunikację z aplikacją webową. Przykłady z książki stanowią wzorce inżynierskie, które trzeba będzie dostosować do specyfiki detekcji odpadów i ograniczeń platformy brzegowej. Framework Ultralytics wykorzystywany w projekcie opiera się na PyTorch, a nie na TensorFlow/Keras, dlatego książka służy jako wzorzec metodyczny, a nie instrukcja implementacji. Pomaga również uzasadnić sposób podziału zbioru danych oraz dbałość o reprodukowalność wyników eksperymentów.

2.2 Badania naukowe

2.2.1 Gore i in. (2025) – AI-Powered Waste Management: Real-Time Garbage Detection and Categorization

Autorzy opisują system automatycznej klasyfikacji odpadów w czasie rzeczywistym, w którym kategoryzacja realizowana jest przez potok detekcji obiektów

oparty na modelu YOLOv8 [5]. Model został zoptymalizowany z użyciem biblioteki TensorFlow Lite z myślą o sortowaniu odpadów na urządzeniach brzegowych. System rozpoznaje m.in. odpady nadające się do recyklingu, organiczne i nienadające się do recyklingu.

Praca jest koncepcyjnie najbliższa projektowanemu rozwiązaniu, ponieważ łączy detektor z rodziny YOLO, konwersję modelu do formatu przeznaczonego dla urządzeń brzegowych oraz kategoryzację odpadów w czasie rzeczywistym. W projekcie posłuży ona jako punkt odniesienia dla ogólnej architektury systemu. Jest to jednak publikacja konferencyjna o niewielkiej objętości, dlatego przedstawione w niej wyniki będą traktowane jako deklaracje autorów i nie będą bezpośrednio porównywane z pomiarami uzyskanymi w niniejszym projekcie, wykonanymi na innym sprzęcie i zbiorze danych.

2.2.2 Xia i in. (2024) – YOLO-MTG: A Lightweight YOLO Model for Multi-Target Garbage Detection

Badanie dotyczy detekcji gęsto ułożonych odpadów wielu kategorii, które w dotychczasowych zbiorach danych były reprezentowane rzadko [6]. Autorzy proponują lekki model YOLO-MTG, w którym siecią ekstrakcji cech jest hybrydowa sieć MobileViTv3, a jednostka ekstrakcji cech (blok MobileViT) została zoptymalizowana przez połączenie bloku EfficientFormer z konwolucją dynamiczną. Dodatkowo struktura *Neck* została przebudowana z użyciem techniki ponownego wykorzystania cech (*feature reuse*), aby ograniczyć utratę informacji w kanałach. Na własnym zbiorze MTG model osiąga 95,4% mAP przy 3,4 mln parametrów.

Publikacja jest istotna dla projektu z dwóch powodów. Po pierwsze, jest przykładem pojedynczego, lekkiego detektora z rodziny YOLO, który jednocześnie lokalizuje i kategoryzuje odpady, a jego autorzy jawnie podkreślają wymóg pracy na urządzeniach o ograniczonych zasobach. Po drugie, pokazuje zależność między dokładnością a rozmiarem modelu, co odpowiada celowi porównania modeli dużych i lekkich. Wyniki zostały uzyskane na własnym zbiorze autorów, dlatego nie są wprost porównywalne z wynikami na innych zbiorach odpadów.

2.2.3 Fezari (2025) – Prospecting SBC ROCK 5B+ with AI Module

Praca ma charakter techniczny i została udostępniona jako preprint (styczeń 2026). Opisuje rozbudowę komputera jednopłytkowego Radxa ROCK 5B+ opartego na układzie RK3588 z wbudowanym NPU o mocy 6 TOPS o moduł przyspieszający DEEPX DX-M1 w formacie M.2, o mocy 25 TOPS [7]. Autor przedstawia środowisko uruchomieniowe modułu (DX-RT) oraz wyniki testów wydajnościowych dla modelu YOLOv5s: według materiałów producenta pojedynczy rdzeń NPU modułu DX-M1 osiąga ok. 216 FPS (średni czas inferencji ok. 4,6 ms), a przy trzech rdzeniach ok. 645 FPS.

Publikacja ma znaczenie pomocnicze. Pokazuje typowy przebieg wdrożenia modelu detekcji na platformie brzegowej opartej na RK3588 (konwersja modelu do formatu akceleratora, uruchomienie przez bibliotekę uruchomieniową, pomiar

przepustowości). Projekt wykorzystuje jednak płytkę ROCK 5C, a nie ROCK 5B+, i będzie opierał się na wbudowanym NPU, a nie na zewnętrznym module DX-M1. Z tego względu z pracy będą wykorzystywane wyłącznie wskazówki metodyczne, a podane wartości FPS nie będą traktowane jako oczekiwane wyniki dla docelowego urządzenia.

2.2.4 Kang i in. (2020) – An Automatic Garbage Classification System Based on Deep Learning

Autorzy projektują system automatycznego kosza na odpady obejmujący konstrukcję sprzętową oraz aplikację mobilną [8]. Odpady są rozdzielane na dwie kategorie (nadające się i nienadające się do recyklingu) przy użyciu dwóch serwomechanizmów sterowanych przez komputer Raspberry Pi. Algorytm klasyfikacji bazuje na sieci ResNet-34, zmodyfikowanej w trzech obszarach: wielocechowej fuzji obrazów wejściowych, ponownego wykorzystania cech w jednostkach rezydualnych oraz nowej funkcji aktywacji. Autorzy podają dokładność klasyfikacji do 99% oraz czas cyklu klasyfikacji 0,95 s.

Praca jest użyteczna jako przykład kompletnego stanowiska łączącego klasyfikację z warstwą mechaniczną i aplikacją użytkownika. Jednocześnie rozwiązuje ona zadanie klasyfikacji obrazu do dwóch klas, a nie detekcji wielu obiektów jednocześnie, co stanowi istotne ograniczenie przy porównaniu z podejściem opartym na detektorze.

2.2.5 O'Mahony i in. (2020) – Deep Learning vs. Traditional Computer Vision

Autorzy omawiają zalety i wady głębokiego uczenia oraz klasycznych metod widzenia komputerowego opartych na ręcznie projektowanych deskryptorach cech (m.in. SIFT, SURF, BRIEF) [9]. Podkreślają, że rozwój głębokiego uczenia nie sprawił, iż techniki klasyczne stały się zbędne, a następnie przeglądają podejścia hybrydowe, które łączą oba rodzaje metod i pozwalają poprawić wyniki lub rozwiązywać problemy słabo dopasowane do głębokiego uczenia. Praca nie dotyczy odpadów.

W projekcie artykuł posłuży jako uzasadnienie wyboru głębokiego uczenia dla zadania detekcji i kategoryzacji odpadów z jednoczesnym uwzględnieniem jego kosztów obliczeniowych, istotnych na urządzeniu brzegowym. Wskazuje on również, że rozwiązania hybrydowe są uznanym kierunkiem. Ewentualne zastosowanie prostego, klasycznego etapu wstępnego (np. wyznaczania obszaru zainteresowania przed uruchomieniem sieci) byłoby jednak pomysłem projektowym wymagającym własnej weryfikacji eksperymentalnej, a nie wnioskiem wynikającym wprost z tej pracy.

2.2.6 Sharshar i in. (2025) – Vision-Language Models for Edge Networks: A Comprehensive Survey

Artykuł jest przeglądem metod optymalizacji modeli wizyjno-językowych (VLM) do wdrożeń na urządzeniach brzegowych o ograniczonej mocy obliczeniowej, pa-

mięci i zasobach energetycznych [10]. Autorzy omawiają techniki kompresji modeli (przycinanie, kwantyzację, destylację wiedzy), rozwiązania sprzętowe, efektywne metody trenowania i dostrajania, wyzwania wdrożeniowe oraz kwestie prywatności, a także zastosowania lekkich modeli VLM, m.in. w monitorowaniu środowiska.

Przegląd dotyczy modeli wizyjno-językowych, a nie detektorów obiektów, dlatego w projekcie będzie wykorzystywany jako źródło ogólnych zasad kompresji i wdrażania modeli na urządzeniach brzegowych (kwantyzacja, przycinanie, kompromis między dokładnością a zasobami) oraz jako punkt wyjścia do rozważań nad kierunkami rozwoju systemu, takimi jak użycie lekkich modeli wizyjno-językowych do generowania opisów raportów.

2.3 Dokumentacja techniczna i narzędzia programistyczne

W realizacji projektu planuje się wykorzystanie bibliotek uczenia maszynowego, frameworka wizyjnego oraz oficjalnej dokumentacji platformy brzegowej.

2.3.1 Scikit-learn

Dokumentacja biblioteki **Scikit-learn** opisuje algorytmy uczenia maszynowego ogólnego przeznaczenia, przetwarzanie wstępne danych, dobór i walidację modeli oraz metryki oceny jakości [11]. W projekcie posłuży przede wszystkim do obliczania metryk klasyfikacji (macierz pomyłek, precyzja, czułość, F1-score) na etapie testowania oraz, w razie potrzeby, do podziału zbioru na część treningową, walidacyjną i testową.

2.3.2 Ultralytics YOLO

Dokumentacja frameworka **Ultralytics** opisuje trenowanie, walidację, wykonywanie predykcji oraz eksport modeli z rodziny YOLO do różnych formatów, w tym formatów przeznaczonych do wdrożeń na urządzeniach brzegowych (m.in. RKNN dla układów Rockchip) [12]. Zawiera też opis metryk oceny detekcji i opcji strojenia hiperparametrów. Posłuży jako główne źródło techniczne przy trenowaniu i dostrajaniu modeli YOLO na wybranym zbiorze odpadów oraz przy przygotowaniu ich do uruchomienia na urządzeniu Radxa.

2.3.3 Radxa ROCK 5C Documentation

Dokumentacja płytki **Radxa ROCK 5C** obejmuje m.in. instalację i konfigurację systemu Radxa OS (opartego na Debianie), opis interfejsów sprzętowych, obsługę GPIO oraz materiały dotyczące tworzenia aplikacji, w tym instalację narzędzi RKNN do uruchamiania modeli na układzie NPU i przykłady wdrożenia modeli YOLO [13]. Płytka występuje w dwóch wariantach (RK3588S2 oraz RK3582 w wersji Lite), które różnią się m.in. mocą NPU. Dokumentacja będzie wykorzystywana do przygotowania urządzenia, konwersji i uruchomienia lżejszych modeli na NPU oraz do obsługi strumienia wideo i komunikacji z aplikacją webową.

2.4 Projekty społecznościowe

W ramach analizy rozwiązań open-source uwzględniono dwa repozytoria dotyczące wizyjnego rozpoznawania odpadów. Są to projekty społecznościowe o różnym stopniu dopracowania, dlatego traktowane są jako źródła inspiracji, a nie jako wiarygodne wyniki porównawcze.

2.4.1 Garbage Classification (rikzze1)

Repozytorium **Garbage Classification** to projekt końcowy kursu poświęconego zastosowaniom uczenia maszynowego i głębokiego uczenia [14]. Zawiera notebook z siecią konwolucyjną klasyfikującą zdjęcia do sześciu klas (cardboard, glass, metal, paper, plastic, trash), wytrenowaną na zbiorze liczącym ok. 2,5 tys. obrazów; autorzy podają dokładność ok. 93%. W projekcie posłuży jako przykład prostego klasyfikatora obrazu oraz podstawowej struktury zbioru danych dla sześciu klas. Jest to klasyfikacja całego obrazu, a nie detekcja obiektów, i nie dotyczy działania w czasie rzeczywistym.

2.4.2 Garbage Detection (vishvaspatel)

Repozytorium **GARBAGE-DETECTION** opisuje system wykrywania śmieci z kamer CCTV zainstalowanych na ulicach [15]. Powiadomienia trafiają do portalu internetowego urzędu miejskiego, pracownicy są alarmowani o konieczności odbioru odpadów, a dashboard analityczny prezentuje ilości odpadów z różnych lokalizacji. Do detekcji użyto modeli YOLOv5n, YOLOv7-tiny i YOLOv8n trenowanych na własnym zbiorze zdjęć skupisk odpadów. W projekcie posłuży jako przykład połączenia detektora z aplikacją webową i raportowaniem oraz jako punkt odniesienia dla lekkich wariantów YOLO. Repozytorium wykrywa skupiska śmieci i nie dzieli ich na frakcje materiałowe.

2.5 Rozwiązania komercyjne

W procesie analizy rynku uwzględniono komercyjne systemy przeznaczone do automatycznego wykrywania odpadów. Ich opisy mają charakter materiałów producentów i nie zawierają danych technicznych ani wyników, dlatego traktowane są wyłącznie jako tło porównawcze.

2.5.1 iOmniscient Garbage Detection

Rozwiązanie **iOmniscient Garbage Detection** (domena Iomni AI) to system analizy wideo wykrywający śmieci i nielegalne porzucanie odpadów, także gdy są częściowo lub całkowicie zasłonięte [16]. Według producenta system wysyła alarm do służb odpowiedzialnych za wywóz odpadów wraz z lokalizacją i zdjęciem oraz pozwala odtworzyć zdarzenie, w którym odpady zostały porzucone. Opis nie wskazuje, aby system rozpoznawał rodzaje (frakcje) odpadów.

2.5.2 Dahua Smart City Waste Detection

Rozwiązanie **Dahua Smart City Waste Detection** wykorzystuje stałe kamery z analityką AI instalowane w pomieszczeniach i punktach zbiórki odpadów [17]. Według producenta wykrywa ono m.in. przepełnione kosze, odpady leżące poza pojemnikiem oraz zmieszane surowce wtórne, a zdarzenia wraz z czasem, obrazem i nagraniem trafiają do platformy zarządzania. Możliwe jest także odtwarzanie komunikatów głosowych na miejscu. Opis nie zawiera informacji o modelach, sprzęcie ani skuteczności rozpoznawania.

3 Literatura

Literatura

[1] Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, 4th edition, 2020. Wydanie amerykańskie. Materiały autorów: `https://aima.eecs.berkeley.edu/`.

[2] Zhi-Hua Zhou. *Machine Learning*. Springer Singapore, 2021. `https://doi.org/10.1007/978-981-15-1967-3`.

[3] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. `https://www.deeplearningbook.org/`.

[4] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media, 3rd edition, 2022. Materiały autora do wydania trzeciego: `https://github.com/ageron/handson-ml3`.

[5] A. Gore, A. Bishoi, and R. S. Kute, "AI-Powered Waste Management: Real-Time Garbage Detection and Categorization," in *2025 12th International Conference on Emerging Trends in Engineering & Technology - Signal and Information Processing (ICETET-SIP)*, 2025, pp. 1–6, doi: 10.1109/ICETETSIP64213.2025.11156908.

[6] Z. Xia, H. Zhou, H. Yu, H. Hu, G. Zhang, J. Hu, and T. He, "YOLO-MTG: a lightweight YOLO model for multi-target garbage detection," *Signal, Image and Video Processing*, vol. 18, pp. 5121–5136, 2024, doi: 10.1007/s11760-024-03220-2.

[7] M. Fezari, "Prospecting SBC ROCK 5B+ with AI Module," preprint, ResearchGate, 2026. Dostęp online: `https://www.researchgate.net/profile/Mohamed-Fezari-2`. [Dostęp: 11.11.2026].

[8] Z. Kang, J. Yang, G. Li, and Z. Zhang, "An Automatic Garbage Classification System Based on Deep Learning," *IEEE Access*, vol. 8, pp. 140019–140029, 2020, doi: 10.1109/ACCESS.2020.3010496.

[9] N. O'Mahony, S. Campbell, A. Carvalho, S. Harapanahalli, G. V. Hernandez, L. Krpalkova, D. Riordan, and J. Walsh, "Deep Learning vs. Traditional Computer Vision," in *Advances in Intelligent Systems and Computing (CVC 2019)*, vol. 943, Springer, Cham, 2020, pp. 128–144, doi: 10.1007/978-3-030-17795-9_10.

[10] A. Sharshar, L. U. Khan, W. Ullah, and M. Guizani, "Vision-Language Models for Edge Networks: A Comprehensive Survey," *IEEE Internet of Things Journal*, vol. 12, no. 16, pp. 32701–32724, 2025, doi: 10.1109/JIOT.2025.3579032.

[11] Scikit-learn developers. *Scikit-learn: Machine Learning in Python*. Dostęp online: `https://scikit-learn.org/stable/`. [Dostęp: 11.05.2026].

[12] Ultralytics. *Ultralytics YOLO Documentation*. Dostęp online: https://docs.ultralytics.com/. [Dostęp: 11.05.2026].

[13] Radxa Computer. *Radxa ROCK 5C Documentation*. Dostęp online: https://docs.radxa.com/en/rock5/rock5c. [Dostęp: 11.05.2026].

[14] Rikzze. *Garbage Classification repository*. Dostęp online: https://github.com/rikzze1/garbage-classification/tree/main. [Dostęp: 11.05.2026].

[15] Vishvas Patel. *GARBAGE-DETECTION repository*. Dostęp online: https://github.com/vishvaspatel/GARBAGE-DETECTION. [Dostęp: 11.05.2026].

[16] Iomni AI. *Garbage Detection Solution*. Dostęp online: https://iomni.ai/garbage-detection/. [Dostęp: 11.05.2026].

[17] Dahua Technology. *Smart City Waste Detection Solution*. Dostęp online: https://www.dahuasecurity.com/uk/solutions/city-solutions/smart-city/waste-detection. [Dostęp: 11.05.2026].